Nama : Johanes Rhesa Sandjaja
NIM : 2802407875

Laporan GSLC Deep Learning

A. Analisa Konseptual

1. Efek Regularisasi pada Batch Normalization

   Batch Normalization menormalkan aktivasi berdasarkan rata-rata dan varians setiap mini-batch. Karena isi batch selalu berubah, statistiknya pun sedikit berbeda di setiap iterasi. Akibatnya, representasi satu citra tidak pernah persis sama. Gangguan acak ini mencegah model menghafal data latih, sehingga BN berperan sebagai regularisasi ringan [1].

   Asumsi bahwa Dropout tidak diperlukan menjadi tidak berlaku dalam beberapa kondisi:

   - **Ukuran batch sangat kecil.** Statistik batch tidak representatif, sehingga pelatihan menjadi tidak stabil.
   - **Data sangat terbatas sementara model besar.** Efek regularisasi BN terlalu lemah untuk mencegah overfitting.
   - **Urutan Dropout dan Batch Normalization kurang tepat.** Kombinasi ini dapat menimbulkan perbedaan perilaku antara fase pelatihan dan pengujian [2].

2. Degradasi terjadi ketika jaringan yang lebih dalam justru memiliki akurasi pelatihan lebih rendah. Karena yang turun adalah akurasi latih, masalahnya bukan overfitting, melainkan kesulitan optimisasi [3]. Secara teori, lapisan tambahan cukup mempelajari fungsi identitas, tetapi tumpukan lapisan nonlinier sulit mendekatinya.

   Skip connection mengubah keluaran blok menjadi $y = F(x) + x$, sehingga blok cukup mempelajari residu $F(x)$. Bila lapisan tambahan tidak berguna, F cukup didorong mendekati nol. Saat backpropagation, gradiennya menjadi:

   $$\partial L/\partial x = \partial L/\partial y \cdot (\partial F/\partial x + I)$$

   Suku identitas I menjaga gradien tetap mengalir ke lapisan awal walaupun $\partial F/\partial x$ kecil. Tanpa jalur ini, chain rule mengalikan banyak turunan bernilai kecil sehingga gradien mengecil secara eksponensial (vanishing gradient).

3.

Dimensi	Feature Extraction	Fine-Tuning
Parameter Terlatih	Hanya head (misal ResNet-18: ±5 ribu untuk 10 kelas)	Sebagian sampai seluruhnya (8,4 juta - 11,2 juta)
Kebutuhan Data	Sedikit (ratusan per kelas cukup)	Lebih besar agar tidak overfit

Komputasi	Rendah; tanpa backward pada backbone, fitur bisa di-cache	Tinggi; menyimpan aktivasi dan optimizer state backbone
Risiko Destructive Update	Tidak ada	Ada, terutama dengan LR besar

Feature extraction tepat dipilih bila data sedikit, domain target mirip ImageNet (misalnya ras hewan), dan komputasi terbatas. Fine-tuning diperlukan bila domain berbeda jauh (misalnya citra medis), data cukup banyak, atau performa feature extraction belum memadai. Fine-tuning sebaiknya dimulai dari lapisan akhir, karena lapisan awal menyimpan fitur umum yang mudah ditransfer, sedangkan lapisan akhir lebih spesifik terhadap tugas asal [4].

4. Augmentasi bertujuan memperkaya variasi data latih agar generalisasi model meningkat. Validation dan test set berfungsi mengukur kinerja secara jujur pada kondisi data sebenarnya. Jika augmentasi acak diterapkan pada data evaluasi, hasilnya menjadi tidak konsisten dan tidak mencerminkan kondisi nyata. Karena itu, data evaluasi cukup diberi praproses tetap seperti penyesuaian ukuran dan normalisasi [5].

   Contoh teknik yang tidak layak untuk klasifikasi ras hewan peliharaan adalah perubahan warna (hue) yang ekstrem. Warna bulu sering menjadi ciri pembeda antar-ras. Bila warnanya diubah, citra bisa menyerupai ras lain padahal labelnya tetap. Hal ini melanggar prinsip invariansi semantik, yaitu augmentasi tidak boleh mengubah makna label.

5. Catastrophic forgetting terjadi ketika model pralatih beradaptasi terlalu cepat sehingga pengetahuan umumnya tertimpa [6]. Pada awal fine-tuning, lapisan klasifikasi baru masih acak dan menghasilkan pembaruan besar yang tidak terarah. Pembaruan ini dapat merusak fitur di backbone.

   Strategi pertama adalah differential learning rate. Lapisan awal diperbarui dengan laju sangat kecil karena fitur umumnya sudah baik, sedangkan lapisan akhir diberi laju lebih besar [7].

   Strategi kedua adalah gradual unfreezing. Lapisan klasifikasi dilatih lebih dulu, lalu backbone dibuka bertahap dari atas ke bawah. Pendekatan ini sejalan dengan praktik memulai dari feature extraction. Setelah lapisan klasifikasi stabil, pembaruan pada backbone menjadi lebih halus [8].

Eksperimen

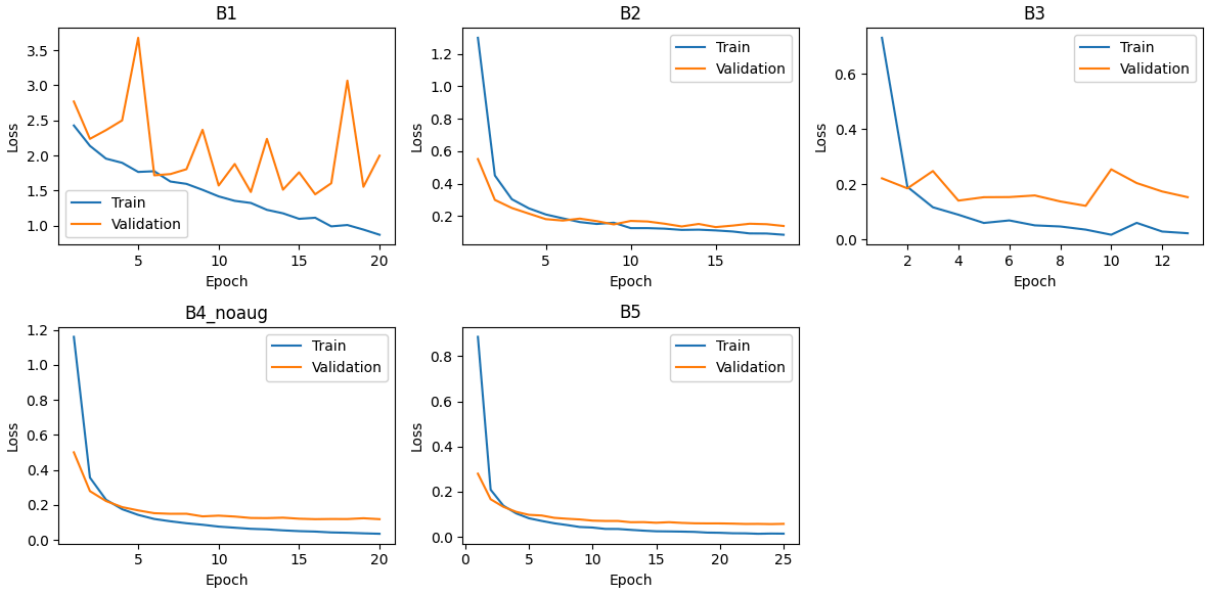
Eksperimen ini membandingkan pelatihan dari nol, feature extraction, fine-tuning sebagian backbone, serta pengaruh augmentasi pada klasifikasi citra dengan data terbatas. Dataset Oxford-IIIT Pet dibatasi menjadi lima ras kucing (Abyssinian, Bengal, Birman, British Shorthair, Siamese) dan lima ras anjing (beagle, boxer, chihuahua, pug, samoyed), dengan total 1.996 citra yang dibagi menjadi 1.397 train, 299 validation, dan 300 test (30 citra per kelas). Anotasi trainval dan test bawaan digabung, lalu dibagi ulang secara stratified dengan rasio mendekati 70:15:15 menggunakan seed 42, dan pemeriksaan indeks memastikan ketiga split tidak saling tumpang tindih.

Seluruh eksperimen menggunakan input 224 × 224, normalisasi ImageNet, batch size 32, optimizer AdamW, CrossEntropyLoss, dan weight decay 0,01, yang dijalankan pada Tesla T4 dengan PyTorch 2.11.0+cu130. Early stopping memantau validation loss dengan patience 4 dan batas maksimal 25 epoch. Statistik BatchNorm pada model pretrained dipertahankan dalam mode evaluasi, dan model terbaik dipilih berdasarkan validation loss sebelum dievaluasi pada test set.

C1. Tabel Konsolidasi & Visualisasi Pembelajaran

Index	Run	Strategy	Params	Total Params	LR	Best Epoch	Epochs Run	Time (s)	Val Loss	Val Acc	Train Acc	Gap (pp)	Test Acc	Test F1
1	B1	From scratch	11,181,642	11,181,642	0.001	16	20	405.41	1.4455	51.84 %	57.48 %	5.64	52.00 %	0.5076
2	B2	Feature extraction (= B4 dengan aug)	5,130	11,181,642	0.001	15	19	324.55	0.1328	95.65 %	97.85 %	2.20	97.67 %	0.9767
3	B3	Progressive fine-tuning (layer4 + fc)	8,398,858	11,181,642	0.0001, 0.001	9	13	227.12	0.1213	95.99 %	99.36 %	3.37	98.67 %	0.9867
4	B4_noaug	Feature extraction tanpa aug	5,130	11,181,642	0.001	16	20	244.84	0.1191	95.65 %	99.57 %	3.92	97.33 %	0.9733
5	B5	Feature extraction tanpa aug (config B4_noaug)	12,810	4,020,358	0.001	24	25	328.09	0.0569	97.99 %	100.00%	2.01	98.67 %	0.9867

Grafik Komparatif kurva training loss vs validation loss :



C2. Pembahasan Analisis Komparatif

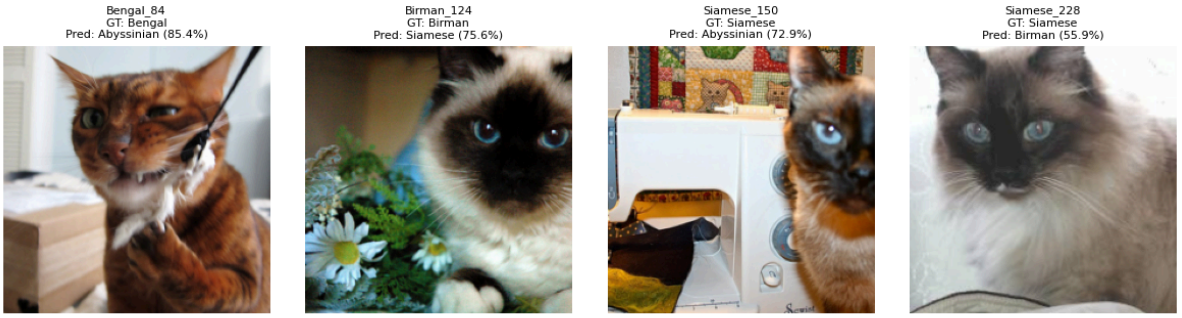
Macro F1 B1 hanya 50,76%, jauh di bawah B2 (97,67%) dan B3 (98,67%). B1 harus mempelajari representasi visual dan classifier sekaligus dari 1.397 citra train, sedangkan B2/B3 memanfaatkan fitur pretrained ImageNet yang relevan untuk citra hewan. Fluktuasi validation loss B1 di tengah train loss yang terus menurun menunjukkan generalisasi yang lemah. Karena B1–B3 sama-sama menggunakan ResNet-18, keunggulan B2/B3 tidak berasal dari skip connection, melainkan dari pretrained initialization dan cakupan parameter yang diperbarui.

Dibandingkan B2, B3 mengurangi kesalahan test dari 7 menjadi 4 dan menaikkan Macro F1 sekitar 1 poin persentase. Namun, trainable parameters meningkat dari 5.130 menjadi 8.398.858, gap train-validation melebar dari 2,20 menjadi 3,37 poin, dan validation loss lebih berfluktuasi. Learning rate backbone yang lebih rendah digunakan untuk mencegah perubahan fitur pretrained yang terlalu agresif. Waktu pelatihan B3 yang lebih singkat (227,12 vs. 324,55 detik) disebabkan oleh early stopping pada epoch ke-13, bukan karena biaya per epoch yang lebih rendah.

B2 dan B4_noaug hanya berbeda pada penggunaan augmentasi (RandomResizedCrop, horizontal flip, rotasi 15 derajat, dan ColorJitter pada train set). Augmentasi menurunkan train accuracy dari 99,57% menjadi 97,85%, sementara validation accuracy tetap 95,65%, sehingga gap menyempit dari 3,92 menjadi 2,20 poin dan Macro F1 test naik dari 97,33% menjadi 97,67%. Hal ini menunjukkan adanya efek regularisasi, meskipun validation loss B4_noaug justru lebih rendah dibandingkan B2.

C3. Failure Analysis (Analisis Kasus Misklasifikasi)

B5 dipilih berdasarkan validation loss terendah, yaitu 0,056868, dan menghasilkan akurasi test sebesar 98,67% (296 dari 300 citra terklasifikasi dengan benar). Setelah seluruh tabel prediksi diperiksa, hanya ditemukan empat kasus misklasifikasi, sehingga keempatnya ditampilkan seluruhnya dalam laporan ini.



Gambar pertama (Bengal): Crop hanya menampilkan kepala berbulu cokelat tanpa pola tubuh khas Bengal, sehingga model kemungkinan keliru membacanya sebagai Abyssinian dengan confidence tinggi.

Gambar kedua (Birman): Wajah gelap, mata biru, dan bulu terang mirip Siamese, sementara kaki dan detail tubuh tidak terlihat utuh.

Gambar ketiga (Siamese): Kepala terpotong dan latar didominasi mesin jahit, sehingga informasi bentuk kepala dan tubuh berkurang.

Gambar keempat (Siamese): Ciri visualnya mirip Birman, dan confidence 55,92% menunjukkan model cukup ragu dalam memprediksi.

C4. Rekomendasi Rekayasa dan Batasan Eksperimen

Konfigurasi B5 dipilih berdasarkan validation loss terendah di antara run ResNet-18, yaitu B4_noaug (0,1191), sedikit di bawah B3 (0,1213). Dengan kriteria ini, test set tidak digunakan untuk memilih konfigurasi, walaupun Macro F1 test B3 lebih tinggi. Karena B5 dan B4_noaug hanya berbeda pada arsitektur backbone, keduanya menjadi pembanding yang setara.

EfficientNet-B0 dengan feature extraction (B5) menjadi kandidat utama, dengan validation loss 0,056868, validation accuracy 97,99%, dan Macro F1 test 98,67%. Dibandingkan B4_noaug, B5 menaikkan prediksi benar pada test set dari 292 menjadi 296 dari 300 citra. Akurasi ini setara dengan B3 tanpa perlu membuka backbone, dengan total parameter sekitar 64% lebih sedikit dan hanya 12.810 parameter yang dilatih. Namun, waktu per epoch B5 sedikit lebih lama (13,1 vs. 12,2 detik), sehingga parameter yang lebih sedikit tidak otomatis berarti lebih cepat. Latensi dan memori pada perangkat deployment tetap perlu diukur.

Jika tetap menggunakan ResNet-18, B2 cukup sebagai titik awal (Macro F1 97,67%), sedangkan B3 dapat dipilih bila tambahan akurasinya sepadan dengan kebutuhan memori. Augmentasi ringan juga layak dicoba karena mengurangi gap pada ResNet-18, tetapi efeknya pada EfficientNet belum diuji.

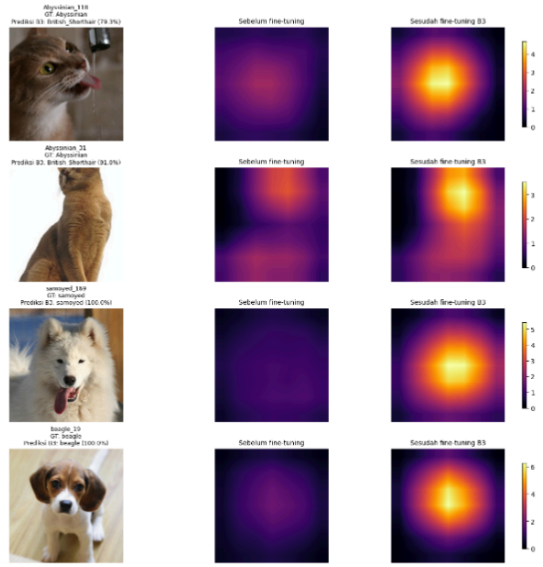
Batasan Eksperimen :

- **Single seed dan split.** Penggunaan seed 42 membuat run dapat diulang, tetapi variasi performa antar seed maupun split belum diukur. Selain itu, perbandingan antarmodel belum dilengkapi confidence interval atau uji signifikansi.
- **Cakupan domain terbatas.** Eksperimen hanya mencakup 10 dari 37 kelas Oxford-IIIT Pet dengan 300 citra test, sehingga performa model belum teruji pada ras lain, kamera berbeda, kelas di luar daftar, maupun kondisi deployment nyata.

- **Kontrol kebocoran terbatas.** Pemeriksaan hanya dilakukan untuk memastikan tidak ada indeks yang sama antar split, tanpa pengecekan near-duplicate maupun kemungkinan overlap dengan data pretraining.
- **Anggaran dan protokol komputasi.** Batas 25 epoch menghentikan B5 sebelum patience terpenuhi, sehingga checkpoint terbaiknya belum tentu menandakan konvergensi. Waktu pelatihan juga dipengaruhi jumlah epoch dan evaluasi yang dilakukan tiap epoch.
- **Evaluasi stabilitas terbatas.** Belum dilakukan pengukuran latensi dan memori untuk produksi, kalibrasi confidence, maupun uji robustness. Selain itu, B3 membekukan statistik BatchNorm dan hanya mengadaptasi sebagian backbone**.**

C5. Eksplorasi Tambahan

Visualisasi membandingkan ResNet-18 pretrained ImageNet dengan checkpoint terbaik B3 pada dua sampel yang salah dan dua sampel yang benar diprediksi oleh B3. Kedua model dijalankan dalam mode evaluasi dengan input dan preprocessing yang sama. Aktivasi layer4 dirata-ratakan dari 512 channel, diperbesar dari 7 × 7 ke ukuran input, dan skala warnanya disamakan dalam tiap pasangan gambar.



Pada gamabr pertama dan kedua, respons setelah fine-tuning meningkat di sekitar kepala dan wajah, tetapi keduanya tetap salah diprediksi sebagai British Shorthair dengan confidence 79,3% dan 91,0%. Sementara itu, samoyed_169 dan beagle_19 menunjukkan aktivasi lebih tinggi di area wajah dan diprediksi dengan benar.

Hasil ini menunjukkan adanya perubahan intensitas dan distribusi aktivasi setelah adaptasi domain. Namun, karena peningkatan juga terjadi pada kasus yang salah, hal ini belum membuktikan bahwa fitur menjadi lebih diskriminatif. Selain itu, peta rata-rata channel bukan Grad-CAM untuk kelas tertentu dan resolusi 7 × 7 membatasi detail spasial, sehingga hasil ini belum dapat menjelaskan penyebab prediksi maupun memastikan tidak terjadi catastrophic forgetting.

Pernyataan Pengunaan AI

Dalam pengerjaan tugas ini, penulis menggunakan ChatGPT untuk membantu memahami maksud soal, menyusun dan memahami kode, serta mencari sumber yang relevan untuk

menjawab soal-soal teori. Seluruh proses training, evaluasi, dan visualisasi dijalankan langsung melalui notebook, dan hasil yang dilaporkan berasal dari eksekusi tersebut. Penulis telah meninjau kembali kode, hasil, dan interpretasi yang disajikan, serta bertanggung jawab penuh atas isi laporan ini.

Referensi

[1] S. Ioffe and C. Szegedy, “Batch normalization: Accelerating deep network training by reducing internal covariate shift,” in *Proc. ICML*, 2015.

[2] X. Li, S. Chen, X. Hu, and J. Yang, “Understanding the disharmony between dropout and batch normalization by variance shift,” in *Proc. CVPR*, 2019.

[3] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” in *Proc. CVPR*, 2016.

[4] J. Yosinski, J. Clune, Y. Bengio, and H. Lipson, “How transferable are features in deep neural networks?,” in *Proc. NeurIPS*, 2014.

[5] C. Shorten and T. M. Khoshgoftaar, “A survey on image data augmentation for deep learning,” *J. Big Data*, vol. 6, no. 60, 2019.

[6] J. Kirkpatrick *et al.*, “Overcoming catastrophic forgetting in neural networks,” *Proc. Natl. Acad. Sci.*, vol. 114, no. 13, 2017.

[7] J. Howard and S. Ruder, “Universal language model fine-tuning for text classification,” in *Proc. ACL*, 2018.

[8] A. Kumar, A. Raghunathan, R. Jones, T. Ma, and P. Liang, “Fine-tuning can distort pretrained features and underperform out-of-distribution,” in *Proc. ICLR*, 2022.